```
import pandas as pd
import csv
import re
import requests
import glob
from rapidfuzz import process, fuzz
import polars as pl
import unidecode
import matplotlib.pyplot as plt
import seaborn as sns
```

```
df=pd.read_csv("dpe03nouvelle_acquitaine_vf.csv" ,sep=",")
```

```
df.isna().sum()
```

```
numero_dpe                              0
date_etablissement_dpe                  0
methode_application_dpe                 0
etiquette_dpe                           0
etiquette_ges                           0
adresse_ban                           369
nom_commune_ban                         0
nom_rue_ban                         23926
code_postal_ban                         0
code_insee_ban                          0
code_departement_ban                    0
code_region_ban                         0
coordonnee_cartographique_x_ban         0
coordonnee_cartographique_y_ban         0
score_ban                               0
adresse_complete_brut                   2
type_batiment                           0
surface_habitable_logement          11988
annee_construction                 255745
nombre_niveau_logement              12864
hauteur_sous_plafond                    0
zone_climatique                      2499
emission_ges_chauffage                 34
emission_ges_ecs                        0
conso_5_usages_ep                      34
emission_ges_5_usages                  34
conso_5 usages_ef                      34
cout_total_5_usages                    35
type_energie_principale_chauffage       0
type_energie_principale_ecs             0
cout_chauffage                         35
cout_ecs                               34
conso_ecs_ef                            0
conso_chauffage_ef                     34
conso_ecs_ep                            0
conso_chauffage_ep                     34
adresse_brut                           10
nom_commune_brut                       13
code_postal_brut                        0
type_installation_chauffage        268349
type_installation_ecs              268349
date_fin_validite_dpe                   0
dtype: int64
```

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 564747 entries, 0 to 564746
Data columns (total 42 columns):
 #   Column                            Non-Null Count   Dtype
---  ------                            --------------   -----
 0   numero_dpe                        564747 non-null  object
 1   date_etablissement_dpe            564747 non-null  object
 2   methode_application_dpe           564747 non-null  object
 3   etiquette_dpe                     564747 non-null  object
 4   etiquette_ges                     564747 non-null  object
 5   adresse_ban                       564378 non-null  object
 6   nom_commune_ban                   564747 non-null  object
 7   nom_rue_ban                       540821 non-null  object
 8   code_postal_ban                   564747 non-null  int64
 9   code_insee_ban                    564747 non-null  int64
 10  code_departement_ban              564747 non-null  int64
 11  code_region_ban                   564747 non-null  int64
 12  coordonnee_cartographique_x_ban   564747 non-null  float64
 13  coordonnee_cartographique_y_ban   564747 non-null  float64
 14  score_ban                         564747 non-null  float64
 15  adresse_complete_brut             564745 non-null  object
 16  type_batiment                     564747 non-null  object
 17  surface_habitable_logement        552759 non-null  float64
 18  annee_construction                309002 non-null  float64
 19  nombre_niveau_logement            551883 non-null  float64
 20  hauteur_sous_plafond              564747 non-null  float64
 21  zone_climatique                   562248 non-null  object
 22  emission_ges_chauffage            564713 non-null  float64
 23  emission_ges_ecs                  564747 non-null  float64
 24  conso_5_usages_ep                 564713 non-null  float64
 25  emission_ges_5_usages             564713 non-null  float64
 26  conso_5 usages_ef                 564713 non-null  float64
 27  cout_total_5_usages               564712 non-null  float64
 28  type_energie_principale_chauffage 564747 non-null  object
 29  type_energie_principale_ecs       564747 non-null  object
 30  cout_chauffage                    564712 non-null  float64
 31  cout_ecs                          564713 non-null  float64
 32  conso_ecs_ef                      564747 non-null  float64
 33  conso_chauffage_ef                564713 non-null  float64
 34  conso_ecs_ep                      564747 non-null  float64
 35  conso_chauffage_ep                564713 non-null  float64
 36  adresse_brut                      564737 non-null  object
 37  nom_commune_brut                  564734 non-null  object
 38  code_postal_brut                  564747 non-null  int64
 39  type_installation_chauffage       296398 non-null  object
 40  type_installation_ecs             296398 non-null  object
 41  date_fin_validite_dpe             564747 non-null  object
dtypes: float64(19), int64(5), object(18)
memory usage: 181.0+ MB
```

```
df.head()
```

	numero_dpe	date_etablissement_dpe	methode_application_dpe	etiquette_dpe	etiquette_ges	adresse_ban	nom_commune_ban	nom_rue_ban	code_postal_ban	code_insee_ban	..
0	2633E0007887V	2026-01-05	dpe maison individuelle	C	A	Fleur 33490 Saint-Maixant	Saint-Maixant	Fleur	33490	33438	
1	2647E0006686E	2026-01-04	dpe maison individuelle	B	A	3 Rue des Cosmonautes 47300 Pujols	Pujols	Rue des Cosmonautes	47300	47215	
2	2633E0027829V	2026-01-06	dpe appartement individuel	C	B	51 Cours Victor Hugo 33000 Bordeaux	Bordeaux	Cours Victor Hugo	33000	33063	
3	2133E0823275S	2021-12-01	dpe maison individuelle	F	F	111 Rue Lamartine 33400 Talence	Talence	Rue Lamartine	33400	33522	
4	2679E0051495V	2026-01-08	dpe maison individuelle	C	B	29 Rue de l'Abbaye 79160 Villiers-en-Plaine	Villiers-en-Plaine	Rue de l'Abbaye	79160	79351	

5 rows × 42 columns

Compte tenu du nombre important des variables, nous allons en choisir que les éssentielles.

```
df['conso_5_usages_ef']=df["conso_5 usages_ef"].rename("conso_5_usages_ef")
cols = [
    'date_etablissement_dpe', 'etiquette_dpe', 'etiquette_ges',
    'adresse_ban', 'coordonnee_cartographique_x_ban', 'coordonnee_cartographique_y_ban',
    'code_postal_ban', 'code_departement_ban', 'nom_commune_ban','code_insee_ban',
    'type_batiment', 'surface_habitable_logement', 'annee_construction',
    'conso_5_usages_ef', 'type_energie_principale_chauffage'
]
df = df[cols]
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 564747 entries, 0 to 564746
Data columns (total 15 columns):
 #   Column                             Non-Null Count   Dtype
---  ------                             --------------   -----
 0   date_etablissement_dpe             564747 non-null  object
 1   etiquette_dpe                      564747 non-null  object
 2   etiquette_ges                      564747 non-null  object
 3   adresse_ban                        564378 non-null  object
 4   coordonnee_cartographique_x_ban    564747 non-null  float64
 5   coordonnee_cartographique_y_ban    564747 non-null  float64
 6   code_postal_ban                    564747 non-null  int64
 7   code_departement_ban               564747 non-null  int64
 8   nom_commune_ban                    564747 non-null  object
 9   code_insee_ban                     564747 non-null  int64
 10  type_batiment                      564747 non-null  object
 11  surface_habitable_logement         552759 non-null  float64
 12  annee_construction                 309002 non-null  float64
 13  conso_5_usages_ef                  564713 non-null  float64
 14  type_energie_principale_chauffage  564747 non-null  object
dtypes: float64(5), int64(3), object(7)
memory usage: 64.6+ MB
```

Netoyage des données

Conversion des types des variables

Les Dates

```
df['date_etablissement_dpe'] = pd.to_datetime(df['date_etablissement_dpe'], errors='coerce')
df['date_etablissement_dpe'].min()
```

```
Timestamp('2021-07-01 00:00:00')
```

les Variables numériques

```
num_cols = [
    'surface_habitable_logement',
    'annee_construction',
    'conso_5_usages_ef',
    'coordonnee_cartographique_x_ban',
    'coordonnee_cartographique_y_ban'
]

for col in num_cols:
    df[col] = pd.to_numeric(df[col], errors='coerce')
```

Les codes

```
df['code_postal_ban'] = df['code_postal_ban'].astype(str)
df['code_departement_ban'] = df['code_departement_ban'].astype(str)
```

Nettoyage des étiquettes énergétiques Les classes DPE doivent être A → G.

```
classes_valides = list("ABCDEFG")

df = df[df['etiquette_dpe'].isin(classes_valides)]
df = df[df['etiquette_ges'].isin(classes_valides)]
```

Encodage des étiquettes DPE

```
dpe_map = {
    'A':7,
    'B':6,
    'C':5,
    'D':4,
    'E':3,
    'F':2,
    'G':1
}

df['score_dpe'] = df['etiquette_dpe'].map(dpe_map)
```

Les valeurs abérantes

Consommation et Surface habitable

```
df.plot.scatter(x='surface_habitable_logement', y='conso_5_usages_ef')
```

```
<Axes: xlabel='surface_habitable_logement', ylabel='conso_5_usages_ef'>
```

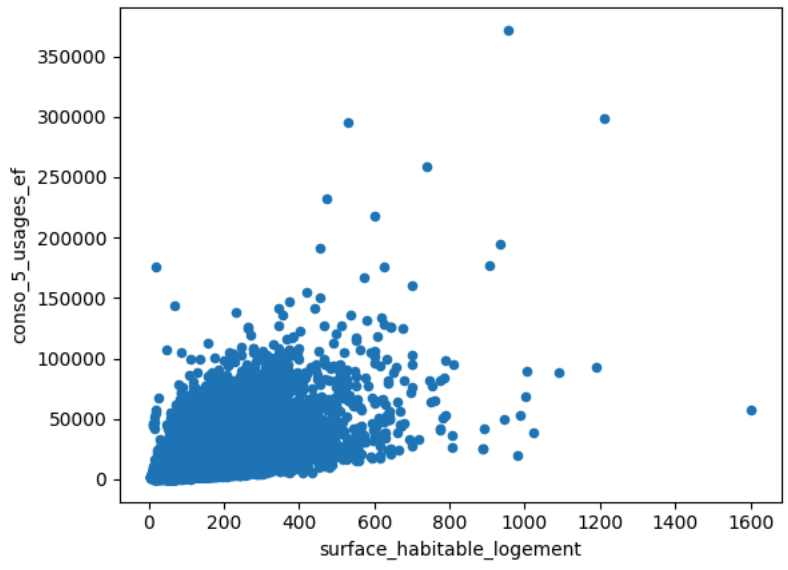

Nous observons une correlation positive entre la consommation et la surface habitale ce qui est logique. Nous pouvons également remarquer quelque outliers sur les deux axes.

Surface habitable On supprime les surfaces absurdes.

```
df=df[(df["surface_habitable_logement"] > 5)]
```

consommation énergetique

```
df = df[(df['conso_5_usages_ef'] > 0)]
```

Nous allons maintenant créer une variable qui mesure la consommation par m² et ensuite nous filtrerons pour avoir limité les erreurs de saisies. Cela pour cadrer un la surface habitable ainsi que la consommation dans un intervalle raisonnable

```
df["conso_m2"] = df["conso_5_usages_ef"] / df["surface_habitable_logement"]
```

```
sns.histplot(df["conso_m2"], bins=100)
plt.xlim(0,1000)
plt.show()
```

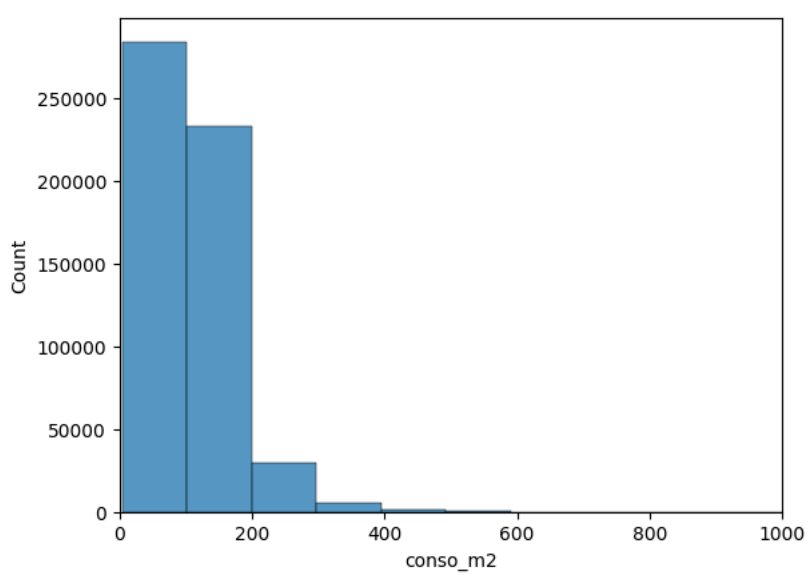


```
df=df[(df["conso_m2"] >20)& (df["conso_m2"] < 600)]
```

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 550828 entries, 0 to 564746
Data columns (total 17 columns):
 #   Column                             Non-Null Count   Dtype
---  ------                             --------------   -----
 0   date_etablissement_dpe             550828 non-null  datetime64[ns]
 1   etiquette_dpe                      550828 non-null  object
 2   etiquette_ges                      550828 non-null  object
 3   adresse_ban                        550460 non-null  object
 4   coordonnee_cartographique_x_ban    550828 non-null  float64
 5   coordonnee_cartographique_y_ban    550828 non-null  float64
 6   code_postal_ban                    550828 non-null  object
 7   code_departement_ban               550828 non-null  object
 8   nom_commune_ban                    550828 non-null  object
 9   code_insee_ban                     550828 non-null  int64
 10  type_batiment                      550828 non-null  object
 11  surface_habitable_logement         550828 non-null  float64
 12  annee_construction                 302388 non-null  float64
 13  conso_5_usages_ef                  550828 non-null  float64
 14  type_energie_principale_chauffage  550828 non-null  object
 15  score_dpe                          550828 non-null  int64
 16  conso_m2                           550828 non-null  float64
dtypes: datetime64[ns](1), float64(6), int64(2), object(8)
memory usage: 75.6+ MB
```

Gestion des valeurs manquantes

Nous avons déjà supprimer pas mal de valeurs manquantes avec les filtrages sur nos variables indispensables. Nous allons maintenant imputer ou supprimer les restantes

```
df.isna().sum()
```

```
date_etablissement_dpe                   0
etiquette_dpe                            0
etiquette_ges                            0
adresse_ban                            368
coordonnee_cartographique_x_ban          0
coordonnee_cartographique_y_ban          0
code_postal_ban                          0
code_departement_ban                     0
nom_commune_ban                          0
code_insee_ban                           0
type_batiment                            0
surface_habitable_logement               0
annee_construction                  248440
conso_5_usages_ef                        0
type_energie_principale_chauffage        0
score_dpe                                0
conso_m2                                 0
dtype: int64
```

Vu le nombre de valeurs manquantes importantes sur la variable année de contruction, nous les imputer plutôt que de les supprimer.

```
def periode_construction(x):
    if pd.isna(x):
        return "Inconnue"
    elif x < 1948:
        return "Avant 1948"
    elif x < 1975:
        return "1948-1974"
    elif x < 1990:
        return "1975-1989"
    elif x < 2005:
        return "1990-2004"
    else:
        return "Après 2005"

df["periode_construction"] = df["annee_construction"].apply(periode_construction)
df = df.drop(columns=["annee_construction"])
```

```
df["periode_construction"].value_counts()
```

```
periode_construction
Inconnue      248440
Après 2005     76364
Avant 1948     73070
1975-1989      53708
1948-1974      51316
1990-2004      47930
Name: count, dtype: int64
```

```
df=df.dropna(subset=["adresse_ban"])
df.isna().sum()
```

```
date_etablissement_dpe               0
etiquette_dpe                        0
etiquette_ges                        0
adresse_ban                          0
coordonnee_cartographique_x_ban      0
coordonnee_cartographique_y_ban      0
code_postal_ban                      0
code_departement_ban                 0
nom_commune_ban                      0
code_insee_ban                       0
type_batiment                        0
surface_habitable_logement           0
conso_5_usages_ef                    0
type_energie_principale_chauffage    0
score_dpe                            0
conso_m2                             0
periode_construction                 0
dtype: int64
```

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 550460 entries, 0 to 564746
Data columns (total 17 columns):
 #   Column                             Non-Null Count   Dtype
---  ------                             --------------   -----
 0   date_etablissement_dpe             550460 non-null  datetime64[ns]
 1   etiquette_dpe                      550460 non-null  object
 2   etiquette_ges                      550460 non-null  object
 3   adresse_ban                        550460 non-null  object
 4   coordonnee_cartographique_x_ban    550460 non-null  float64
 5   coordonnee_cartographique_y_ban    550460 non-null  float64
 6   code_postal_ban                    550460 non-null  object
 7   code_departement_ban               550460 non-null  object
 8   nom_commune_ban                    550460 non-null  object
 9   code_insee_ban                     550460 non-null  int64
 10  type_batiment                      550460 non-null  object
 11  surface_habitable_logement         550460 non-null  float64
 12  conso_5_usages_ef                  550460 non-null  float64
 13  type_energie_principale_chauffage  550460 non-null  object
 14  score_dpe                          550460 non-null  int64
 15  conso_m2                           550460 non-null  float64
 16  periode_construction               550460 non-null  object
dtypes: datetime64[ns](1), float64(5), int64(2), object(9)
memory usage: 75.6+ MB
```

Les doublons

```
df.duplicated().sum()
```

```
np.int64(20412)
```

Nous avons plus de 20000 doublons, nous allons les supprimer

```
df = df.drop_duplicates()
```

Vérification finale

```
print(df.info())
print(df.describe())
print(df.isna().sum())
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 530048 entries, 0 to 564746
Data columns (total 17 columns):
 #   Column                             Non-Null Count   Dtype
---  ------                             --------------   -----
```

```
 0   date_etablissement_dpe             530048 non-null  datetime64[ns]
 1   etiquette_dpe                      530048 non-null  object
 2   etiquette_ges                      530048 non-null  object
 3   adresse_ban                        530048 non-null  object
 4   coordonnee_cartographique_x_ban    530048 non-null  float64
 5   coordonnee_cartographique_y_ban    530048 non-null  float64
 6   code_postal_ban                    530048 non-null  object
 7   code_departement_ban               530048 non-null  object
 8   nom_commune_ban                    530048 non-null  object
 9   code_insee_ban                     530048 non-null  int64
 10  type_batiment                      530048 non-null  object
 11  surface_habitable_logement         530048 non-null  float64
 12  conso_5_usages_ef                  530048 non-null  float64
 13  type_energie_principale_chauffage  530048 non-null  object
 14  score_dpe                          530048 non-null  int64
 15  conso_m2                           530048 non-null  float64
 16  periode_construction               530048 non-null  object
dtypes: datetime64[ns](1), float64(5), int64(2), object(9)
memory usage: 72.8+ MB
None
              date_etablissement_dpe  coordonnee_cartographique_x_ban  \
count                          530048                    530048.000000
mean   2023-11-12 21:54:29.699347456                    442544.684812
min              2021-07-01 00:00:00                         0.559325
25%              2022-10-11 00:00:00                    394570.315000
50%              2023-11-15 00:00:00                    422717.690000
75%              2025-01-03 00:00:00                    492150.127500
max              2026-03-02 00:00:00                    667625.660000
std                              NaN                     68253.725320

       coordonnee_cartographique_y_ban  code_insee_ban  \
count                     5.300480e+05   530048.000000
mean                      6.447119e+06    42506.608628
min                       4.549365e+01    16001.000000
25%                       6.391312e+06    24167.000000
50%                       6.429098e+06    33281.000000
75%                       6.528465e+06    64122.000000
max                       6.677423e+06    87206.000000
std                       1.091744e+05    23367.330408

       surface_habitable_logement  conso_5_usages_ef      score_dpe  \
count               530048.000000      530048.000000  530048.000000
mean                    74.591122        7989.529619       4.341778
min                      5.200000         337.200000       1.000000
25%                     41.700000        3765.100000       4.000000
50%                     65.900000        5983.800000       4.000000
75%                     94.600000        9749.200000       5.000000
max                   1603.000000      371913.700000       7.000000
std                     46.916981        6902.823443       1.194127

            conso_m2
count  530048.000000
mean      110.758961
```

Dataset final

```
df_clean = df.copy()
```

CONSOMMATION ENEDIS

```
consommation=pd.read_csv("consommation-annuelle-residentielle-par-adresse (1).csv" ,sep=";")
df_consommation = consommation[consommation['Code Région'].astype(str).str.startswith("75")]
df_consommation=df_consommation[consommation["Année"]>2020]
```

```
C:\Users\Utilisateur\AppData\Local\Temp\ipykernel_14284\2847080377.py:1: DtypeWarning: Columns (1,15) have mixed types. Specify dtype option on import or set low_memory=False.
  consommation=pd.read_csv("consommation-annuelle-residentielle-par-adresse (1).csv" ,sep=";")
C:\Users\Utilisateur\AppData\Local\Temp\ipykernel_14284\2847080377.py:3: UserWarning: Boolean Series key will be reindexed to match DataFrame index.
  df_consommation=df_consommation[consommation["Année"]>2020]
```

Nous filtrons Année sur 2020 comme demander dans les consignes (puisqu'on travaille sur les données de DPE disponible qu'à partir de juillet 2021)

```
df_consommation.head()
```

	Année	Code IRIS	Nom IRIS	Numéro de voie	Indice de répétition	Type de voie	Libellé de voie	Code Commune	Nom Commune	Segment de client	Nombre de logements	Consommation annuelle totale de l'adresse (MWh)	Consommation annuelle moyenne par logement de l'adresse (MWh)	Consommation annuelle moyenne de la commune (MWh)	Adresse
142033	2021	470010111	Montanou	5.0	NaN	RUE	BLAISE DE MONLUC	47001	Agen	RESIDENTIEL	56	83.869	1.498	3.198	5 RUE BLAISE DE MONLUC
142034	2021	470010101	Centre Urbain 1	117.0	NaN	BOULEVARD	CARNOT	47001	Agen	RESIDENTIEL	27	31.891	1.181	3.198	117 BOULEVARD CARNOT
142035	2021	470010107	Ouest Urbain	69.0	NaN	BOULEVARD	DE LA LIBERTE	47001	Agen	RESIDENTIEL	19	78.599	4.137	3.198	69 BOULEVARD DE LA LIBERTE
142036	2021	470010112	Nord-Est Urbain	62.0	NaN	RUE	DE LA PRUNE	47001	Agen	RESIDENTIEL	10	31.502	3.150	3.198	62 RUE DE LA PRUNE
142037	2021	470010108	Nord Urbain 1	9.0	NaN	RUE	DE LA REINE	47001	Agen	RESIDENTIEL	16	25.604	1.600	3.198	9 RUE DE LA REINE

Selection des variables utiles

```
cols_enedis = [
    "Code Commune",
    "Nom Commune",
    "Adresse",
    "Année",
    "Segment de client",
    "Consommation annuelle totale de l'adresse (MWh)",
    "Consommation annuelle moyenne par logement de l'adresse (MWh)",
    'Consommation annuelle moyenne de la commune (MWh)',
    "Nombre de logements"
]

df_consommation = df_consommation[cols_enedis]
```

```
df_consommation.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 84948 entries, 142033 to 2820482
Data columns (total 9 columns):
```

```
 #   Column                                                  Non-Null Count  Dtype
---  ------                                                  --------------  -----
 0   Code Commune                                            84948 non-null  int64
 1   Nom Commune                                             84948 non-null  object
 2   Adresse                                                 84948 non-null  object
 3   Année                                                   84948 non-null  int64
 4   Segment de client                                       84948 non-null  object
 5   Consommation annuelle totale de l'adresse (MWh)         84948 non-null  float64
 6   Consommation annuelle moyenne par logement de l'adresse (MWh)  84948 non-null  float64
 7   Consommation annuelle moyenne de la commune (MWh)       84948 non-null  float64
 8   Nombre de logements                                     84948 non-null  int64
dtypes: float64(3), int64(3), object(3)
memory usage: 6.5+ MB
```

```
df_consommation.isna().sum()
```

```
Code Commune                                                0
Nom Commune                                                 0
Adresse                                                     0
Année                                                       0
Segment de client                                           0
Consommation annuelle totale de l'adresse (MWh)             0
Consommation annuelle moyenne par logement de l'adresse (MWh)    0
Consommation annuelle moyenne de la commune (MWh)           0
Nombre de logements                                         0
dtype: int64
```

```
df_consommation.duplicated().sum()
```

```
np.int64(0)
```

A priori pas de doublons, ni de valeurs manquantes.

Nettoyage des types

```
df_consommation["Année"] = pd.to_numeric(df_consommation["Année"], errors="coerce")

df_consommation["Consommation annuelle moyenne par logement de l'adresse (MWh)"] = pd.to_numeric(
    df_consommation["Consommation annuelle moyenne par logement de l'adresse (MWh)"], errors="coerce"
)

df_consommation["Consommation annuelle totale de l'adresse (MWh)"] = pd.to_numeric(
    df_consommation["Consommation annuelle totale de l'adresse (MWh)"], errors="coerce"
)


df_consommation["Consommation annuelle moyenne de la commune (MWh)"] = pd.to_numeric(
    df_consommation["Consommation annuelle moyenne de la commune (MWh)"], errors="coerce"
)


df_consommation["Nombre de logements"] = pd.to_numeric(df_consommation["Nombre de logements"], errors="coerce")

df_consommation["Code Commune"] = df_consommation["Code Commune"].astype(str)
```

Standardiser les noms de communes

```
df_consommation["Nom Commune"] = (
    df_consommation["Nom Commune"]
    .str.upper()
    .str.strip()
)
```

Vérification finale

```
print(df_consommation.info())
print(df_consommation.describe())
print(df_consommation.isna().sum())
print(df_consommation.duplicated().sum())
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 84948 entries, 142033 to 2820482
Data columns (total 9 columns):
 #   Column                                                  Non-Null Count  Dtype
---  ------                                                  --------------  -----
 0   Code Commune                                            84948 non-null  object
 1   Nom Commune                                             84948 non-null  object
 2   Adresse                                                 84948 non-null  object
 3   Année                                                   84948 non-null  int64
 4   Segment de client                                       84948 non-null  object
 5   Consommation annuelle totale de l'adresse (MWh)         84948 non-null  float64
 6   Consommation annuelle moyenne par logement de l'adresse (MWh)  84948 non-null  float64
 7   Consommation annuelle moyenne de la commune (MWh)       84948 non-null  float64
 8   Nombre de logements                                     84948 non-null  int64
dtypes: float64(3), int64(2), object(4)
memory usage: 6.5+ MB
None
              Année  Consommation annuelle totale de l'adresse (MWh)  \
count  84948.000000                                       84948.000000
mean    2022.524580                                          54.283507
std        1.121702                                          58.293906
min     2021.000000                                           0.094000
25%     2022.000000                                          22.297750
50%     2023.000000                                          36.916500
75%     2024.000000                                          63.224000
max     2024.000000                                        1280.275000

       Consommation annuelle moyenne par logement de l'adresse (MWh)  \
count                                        84948.000000
mean                                             2.373421
std                                              1.390082
min                                              0.008000
25%                                              1.381000
50%                                              1.847000
75%                                              3.190000
max                                             15.043000

       Consommation annuelle moyenne de la commune (MWh)  Nombre de logements
count                                       84948.000000         84948.000000
mean                                            3.410709            23.723560
std                                             0.870913            21.335175
min                                             1.771000            10.000000
25%                                             2.837000            12.000000
50%                                             3.142000            17.000000
75%                                             3.773000            27.000000
max                                             8.392000           412.000000
Code Commune                                                   0
Nom Commune                                                    0
Adresse                                                        0
Année                                                          0
Segment de client                                              0
```

```
Consommation annuelle totale de l'adresse (MWh)                 0
Consommation annuelle moyenne par logement de l'adresse (MWh)    0
Consommation annuelle moyenne de la commune (MWh)               0
Nombre de logements                                             0
dtype: int64
0
```

Préparation de la jointure des deux tables (Données DPE et Données consommation Enedis)

```
df_clean["adresse_ban"]=df_clean["adresse_ban"].str.replace(r'\d{5}.*$', '', regex=True)     # Supprime Code Postal + Ville



df_clean["Adresse_complete"]=df_clean["adresse_ban"].fillna("").astype(str).str.strip() + " " + df_clean["code_insee_ban"].fillna("").astype(str) + " " + df_clean["nom_commur
df_clean["Adresse_complete"]= df_clean["Adresse_complete"].str.upper()


df_consommation["Adresse_complete"]=df_consommation["Adresse"].fillna("").astype(str).str.strip() + " " + df_consommation["Code Commune"].fillna("").astype(str) + " " + df_cc
df_consommation["Adresse_complete"]= df_consommation["Adresse_complete"].str.upper()
```

```
Dpe_enedis=pd.merge(df_clean, df_consommation, on="Adresse_complete", how="inner")
Dpe_enedis.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 206836 entries, 0 to 206835
Data columns (total 27 columns):
 #   Column                                                  Non-Null Count   Dtype
---  ------                                                  --------------   -----
 0   date_etablissement_dpe                                  206836 non-null  datetime64[ns]
 1   etiquette_dpe                                           206836 non-null  object
 2   etiquette_ges                                           206836 non-null  object
 3   adresse_ban                                             206836 non-null  object
 4   coordonnee_cartographique_x_ban                         206836 non-null  float64
 5   coordonnee_cartographique_y_ban                         206836 non-null  float64
 6   code_postal_ban                                         206836 non-null  object
 7   code_departement_ban                                    206836 non-null  object
 8   nom_commune_ban                                         206836 non-null  object
 9   code_insee_ban                                          206836 non-null  int64
 10  type_batiment                                           206836 non-null  object
 11  surface_habitable_logement                              206836 non-null  float64
 12  conso_5_usages_ef                                       206836 non-null  float64
 13  type_energie_principale_chauffage                       206836 non-null  object
 14  score_dpe                                               206836 non-null  int64
 15  conso_m2                                                206836 non-null  float64
 16  periode_construction                                    206836 non-null  object
 17  Adresse_complete                                        206836 non-null  object
 18  Code Commune                                            206836 non-null  object
 19  Nom Commune                                             206836 non-null  object
 20  Adresse                                                 206836 non-null  object
 21  Année                                                   206836 non-null  int64
 22  Segment de client                                       206836 non-null  object
 23  Consommation annuelle totale de l'adresse (MWh)         206836 non-null  float64
 24  Consommation annuelle moyenne par logement de l'adresse (MWh)  206836 non-null  float64
 25  Consommation annuelle moyenne de la commune (MWh)       206836 non-null  float64
 26  Nombre de logements                                     206836 non-null  int64
dtypes: datetime64[ns](1), float64(8), int64(4), object(14)
memory usage: 42.6+ MB
```

```
print(Dpe_enedis.isna().sum())
print(Dpe_enedis.duplicated().sum())
```

```
date_etablissement_dpe                                  0
etiquette_dpe                                           0
etiquette_ges                                           0
adresse_ban                                             0
coordonnee_cartographique_x_ban                         0
coordonnee_cartographique_y_ban                         0
code_postal_ban                                         0
code_departement_ban                                    0
nom_commune_ban                                         0
code_insee_ban                                          0
type_batiment                                           0
surface_habitable_logement                              0
conso_5_usages_ef                                       0
type_energie_principale_chauffage                       0
score_dpe                                               0
conso_m2                                                0
periode_construction                                    0
Adresse_complete                                        0
Code Commune                                            0
Nom Commune                                             0
Adresse                                                 0
Année                                                   0
Segment de client                                       0
Consommation annuelle totale de l'adresse (MWh)         0
Consommation annuelle moyenne par logement de l'adresse (MWh)    0
Consommation annuelle moyenne de la commune (MWh)       0
Nombre de logements                                     0
dtype: int64
0
```

```
Dpe_enedis.to_csv("dpe03nouvelle_acquitaine_enedis.csv", index=False)
```

```
Dpe_enedis.head()
```

	date_etablissement_dpe	etiquette_dpe	etiquette_ges	adresse_ban	coordonnee_cartographique_x_ban	coordonnee_cartographique_y_ban	code_postal_ban	code_departement_ban
0	2022-06-13	F	D	11 Rue des Acacias	521460.47	6457513.30	24000	24
1	2022-06-13	F	D	11 Rue des Acacias	521460.47	6457513.30	24000	24
2	2022-06-13	F	D	11 Rue des Acacias	521460.47	6457513.30	24000	24
3	2022-06-13	F	D	11 Rue des Acacias	521460.47	6457513.30	24000	24
4	2026-01-05	D	B	104 Rue du Faubourg Saint Cyprien	496498.37	6611231.36	86000	86

5 rows × 27 columns

Réponses aux problématiques

```
df_final = Dpe_enedis.copy()
```

Vérifier la distribution des classes DPE

```
A=df_final['etiquette_dpe'].value_counts().sort_index()
percentages = (A / A.sum()) * 100
for label, percentage in percentages.items():
    print(f"{label}: {percentage:.2f}%")
```

```
A: 0.69%
B: 5.45%
C: 57.79%
D: 26.53%
E: 7.14%
F: 1.62%
G: 0.77%
```

```
couleurs_dpe = {
    "A": "#009640",
    "B": "#5AB031",
    "C": "#F7EA00",
    "D": "#F7A600",
    "E": "#E94E1B",
    "F": "#D71920",
    "G": "#9B2423"
}

ordre = list("ABCDEFG")

sns.countplot(
    data=df_final,
    x="etiquette_dpe",
    order=ordre,
    palette=[couleurs_dpe[c] for c in ordre]
)

plt.title("Répartition des classes DPE")
plt.show()
```

```
C:\Users\Utilisateur\AppData\Local\Temp\ipykernel_14284\937141456.py:13: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

  sns.countplot(
```

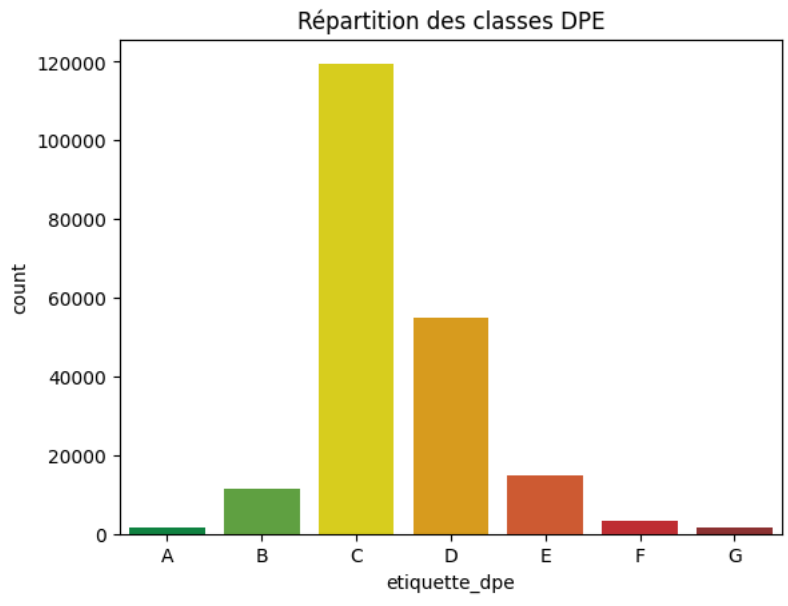

La répartition des classes DPE met en évidence un parc immobilier globalement situé dans la moyenne nationale, avec une forte concentration de logements classés C et D, qui constituent le cœur du graphique. Ces deux catégories traduisent des bâtiments offrant une performance énergétique correcte mais perfectible, souvent associés à des constructions d'après-guerre ou à des logements ayant bénéficié de rénovations partielles. Les classes E, F et G, bien que présentes, restent moins représentées : elles correspondent aux logements les plus énergivores, généralement anciens et peu isolés, mais leur proportion limitée indique que les "passoires thermiques" ne dominent pas l'échantillon. À l'inverse, les classes A et B apparaissent très marginales, ce qui est cohérent avec un territoire où les bâtiments récents ou très performants restent minoritaires. Dans l'ensemble, cette distribution suggère un parc immobilier plutôt ancien, hétérogène, mais sans concentration excessive de logements très dégradés sur le plan énergétique.

Consommation estimée par classe DPE

```
conso_dpe = df_final.groupby("etiquette_dpe")["conso_5_usages_ef"].mean()
print(conso_dpe)
```

```
etiquette_dpe
A    1935.544140
B    3220.358870
C    3843.721196
D    5057.450369
E    6538.976727
F    8265.281574
G    9477.492317
Name: conso_5_usages_ef, dtype: float64
```

```
plt.figure(figsize=(10,6))

# Création du boxplot
ax = sns.boxplot(
    data=df_final,
    x="etiquette_dpe",
    y="conso_5_usages_ef",
    order=ordre
)

# Application des couleurs officielles
for patch, classe in zip(ax.artists, ordre):
    patch.set_facecolor(couleurs_dpe[classe])

plt.title("Consommation estimée selon la classe DPE")
plt.xlabel("Classe DPE")
```

```
plt.ylabel("Consommation (kWh/an)")
plt.show()
```

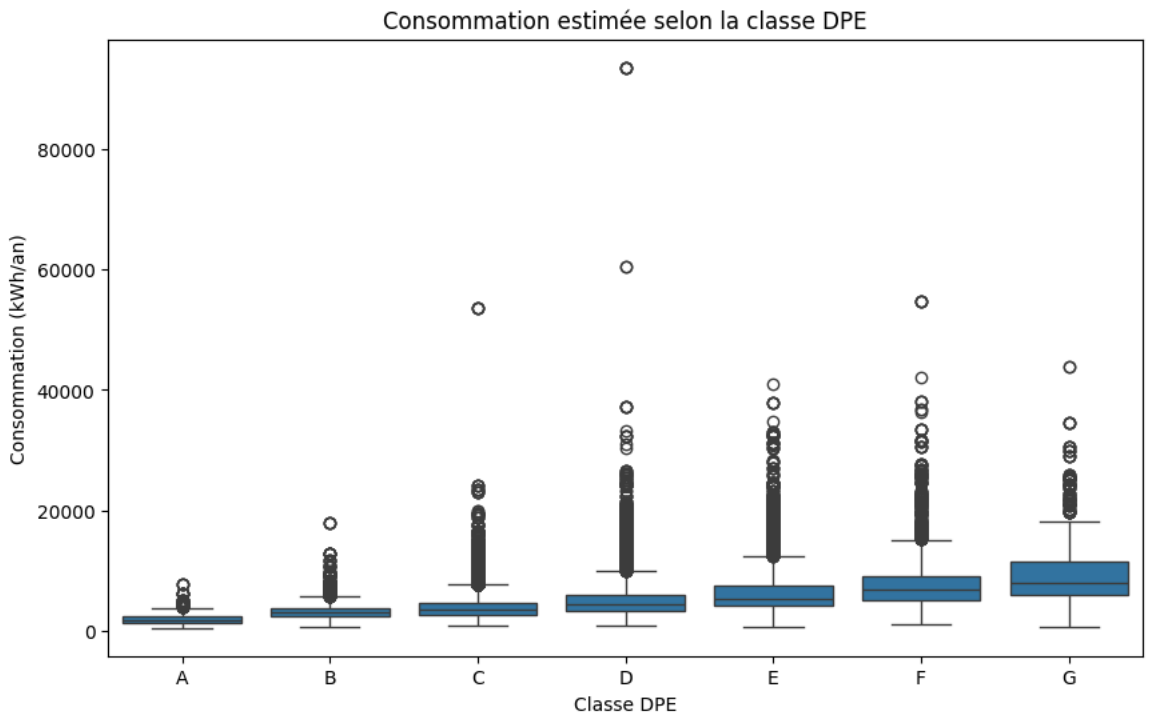

Avec La représentation en boxplots de la consommation énergétique selon les classes DPE nous remarquons une progression nette et cohérente entre les catégories. Les classes les mieux notées, comme A, B et C, présentent des niveaux de consommation nettement plus faibles et des distributions resserrées, traduisant des logements performants et relativement homogènes. À partir de la classe D, la dispersion augmente, signe d'une plus grande hétérogénéité des bâtiments et de leurs niveaux d'isolation. Les classes E, F et surtout G affichent des consommations médianes nettement plus élevées, accompagnées de nombreux points atypiques, ce qui reflète la présence de logements très énergivores, souvent anciens ou mal rénovés. L'ensemble confirme la logique du DPE : plus la classe est dégradée, plus la consommation estimée augmente, tant en valeur centrale qu'en variabilité.

Comparaison consommation dpe et consommation réelle

```
df_final["Consommation annuelle totale de l'adresse (kWh)"]=df_final["Consommation annuelle totale de l'adresse (MWh)"]*1000
df_final["Consommation annuelle moyenne par logement de l'adresse (kWh)"]=df_final["Consommation annuelle moyenne par logement de l'adresse (MWh)"]*1000
```

```
df_final.groupby("etiquette_dpe")[
    ["conso_5_usages_ef", "Consommation annuelle moyenne par logement de l'adresse (kWh)"]
].mean()
```

etiquette_dpe	conso_5_usages_ef	Consommation annuelle moyenne par logement de l'adresse (kWh)
A	1935.544140	2611.315789
B	3220.358870	3495.517865
C	3843.721196	3441.790503
D	5057.450369	3121.809253
E	6538.976727	2759.490830
F	8265.281574	2675.456172
G	9477.492317	2621.288413

```
df_plot = df_final.groupby("etiquette_dpe")[
    ["conso_5_usages_ef", "Consommation annuelle moyenne par logement de l'adresse (kWh)"]
].mean().reset_index()

df_plot.plot(x="etiquette_dpe", kind="bar")
plt.title("Consommation finale estimée vs réelle selon DPE")
plt.ylabel("kWh/an")
plt.show()
```

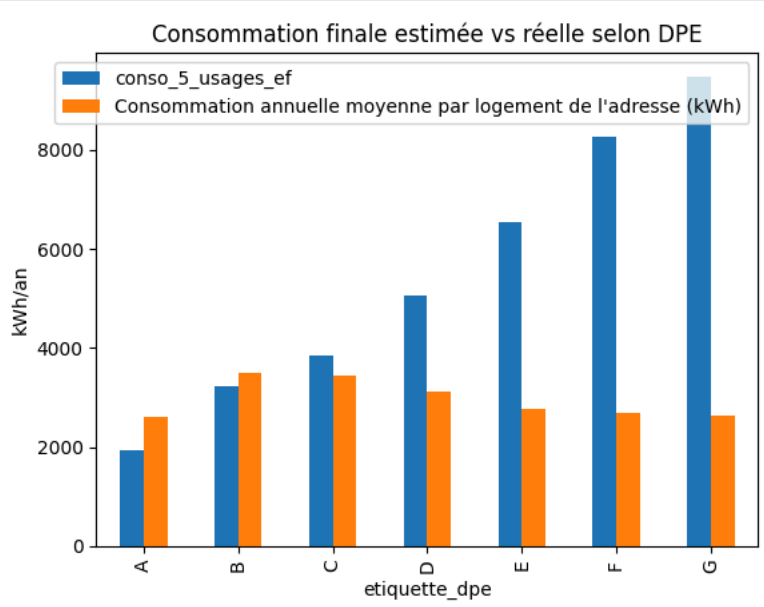

La comparaison entre la consommation finale estimée par le DPE et la consommation réelle mesurée par Enedis met en évidence une cohérence globale dans la hiérarchie énergétique des logements : les classes les mieux notées (A, B, C) présentent des niveaux de consommation plus faibles, tandis que les classes dégradées (E, F, G) affichent des valeurs nettement plus élevées. Toutefois, on observe systématiquement que les consommations réelles sont inférieures aux consommations estimées par le modèle réglementaire du DPE. Cet écart s'explique par le caractère conventionnel du DPE, qui repose sur des hypothèses standardisées d'occupation et de chauffage, alors que les ménages adaptent leurs usages, notamment dans les logements énergivores où le chauffage est souvent réduit pour limiter les coûts. L'écart entre estimation et réalité devient particulièrement marqué dans les classes F et G, ce qui traduit à la fois la forte déperdition thermique de ces logements et les stratégies de restriction adoptées par leurs occupants. Au final, le graphique confirme que le DPE classe correctement les logements en termes de performance énergétique, tout en surestimant la consommation réelle, surtout dans les passoires thermiques.

Variabilité des consommations

On regarde l'écart.

```
df_final["ecart_conso"] = abs(
    df_final["Consommation annuelle moyenne par logement de l'adresse (kWh)"] -
    df_final["conso_5_usages_ef"]
)
sns.histplot(df_final["ecart_conso"], bins=50)
plt.title("Distribution des écarts entre consommation réelle et estimée")
plt.xlabel("Écart (kWh)")
plt.ylabel("Fréquence")
plt.show()
```

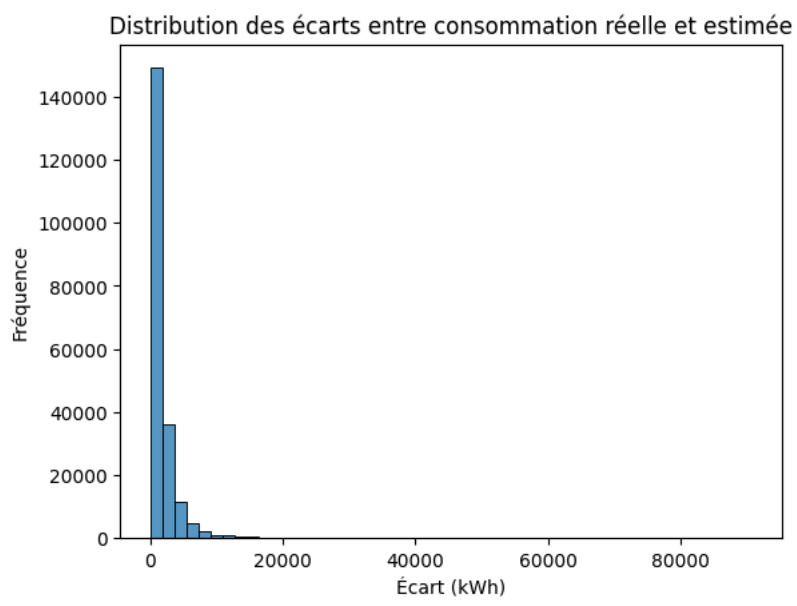


```
plt.figure(figsize=(18,5))


plt.subplot(1, 3, 1)
sns.boxplot(
    data=df_final,
    x="etiquette_dpe",
    y="ecart",
    order=list("ABCDEFG")
)
plt.axhline(0, color="black", linestyle="--")
plt.title("Écarts réel – estimé par classe DPE")
plt.xlabel("Classe DPE")
plt.ylabel("Écart (kWh/an)")


plt.subplot(1, 3, 2)
sns.kdeplot(df_final["ecart"], fill=True)
plt.axvline(0, color="black", linestyle="--")
plt.title("Distribution lissée des écarts")
plt.xlabel("Écart (kWh/an)")
plt.ylabel("Densité")


plt.subplot(1, 3, 3)
sns.scatterplot(
    x=df_final["conso_5_usages_ef"],
    y=df_final["Consommation annuelle moyenne par logement de l'adresse (kWh)"],
    alpha=0.4
)
max_val = max(
    df_final["conso_5_usages_ef"].max(),
    df_final["Consommation annuelle moyenne par logement de l'adresse (kWh)"].max()
)
plt.plot([0, max_val], [0, max_val], color="red", linestyle="--")
plt.title("Consommation réelle vs estimée")
plt.xlabel("Estimée (kWh/an)")
plt.ylabel("Réelle (kWh/an)")

plt.tight_layout()
plt.show()
```

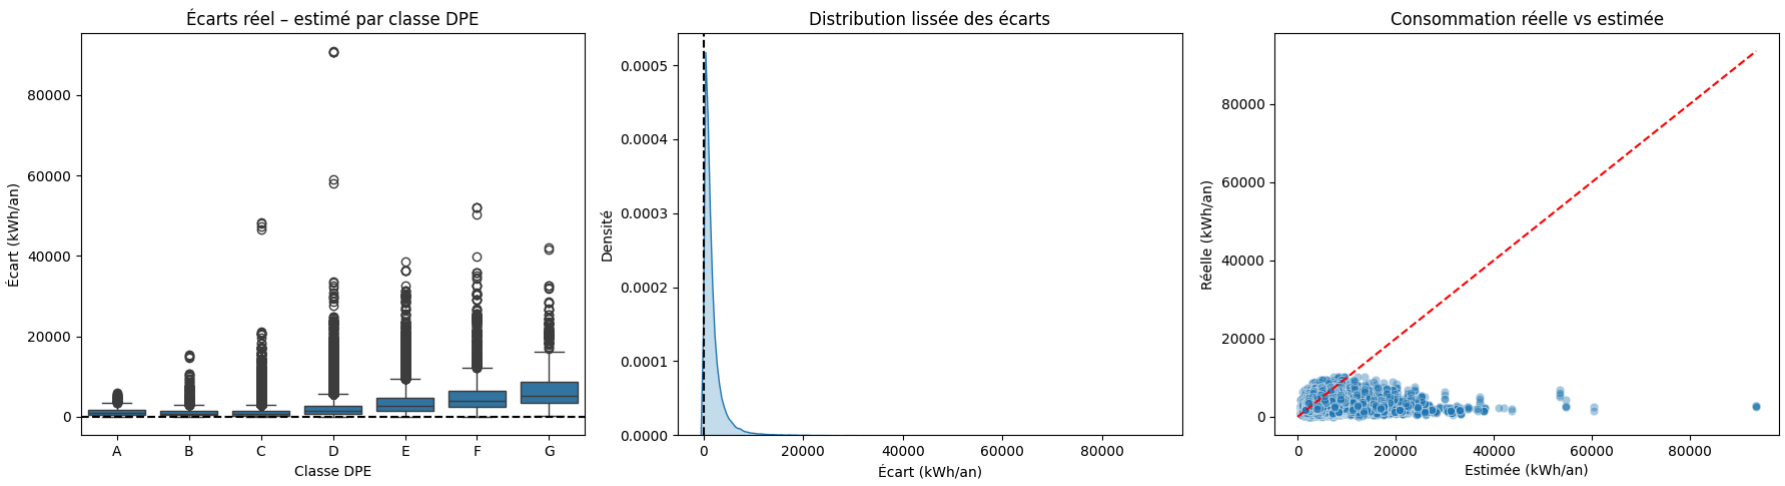

L'analyse conjointe des trois graphiques nous fait remarquer la variabilité entre la consommation réelle mesurée par Enedis et la consommation finale estimée par le DPE. Le boxplot des écarts par classe DPE montre que, pour toutes les classes, les valeurs réelles s'écartent sensiblement des valeurs théoriques, avec une dispersion particulièrement marquée dans les classes énergivores (E, F, G). Cette dispersion traduit directement l'influence des comportements individuels : température de chauffage, durée d'utilisation, pièces non chauffées, sobriété volontaire ou contraintes économiques. La courbe de densité confirme cette observation en révélant une distribution fortement asymétrique, centrée sur des écarts négatifs, ce qui indique que la majorité des ménages consomment moins que ce que le modèle réglementaire prévoit. Enfin, le nuage de points réel vs estimé montre une dispersion verticale importante autour de la diagonale théorique, signe que deux logements identiques sur le plan technique peuvent présenter des consommations très différentes selon les

usages. L'ensemble de ces résultats démontre que la variabilité comportementale constitue un facteur majeur d'écart entre consommation théorique et consommation observée, et qu'elle augmente nettement dans les logements les moins performants.

Gain potentiel d'une rénovation

```
# Moyenne des consommations par classe
gain_dpe = df_final.groupby("etiquette_dpe")["conso_5_usages_ef"].mean()
gain_dpe = gain_dpe.reindex(list("ABCDEFG"))

# Calcul des gains entre classes successives
gain_diff = gain_dpe.diff().abs()

plt.figure(figsize=(18,5))


plt.subplot(1, 3, 1)
sns.barplot(x=gain_dpe.index, y=gain_dpe.values, palette="viridis")
plt.title("Consommation moyenne par classe DPE")
plt.ylabel("kWh/an")
plt.xlabel("Classe DPE")


plt.subplot(1, 3, 2)
sns.barplot(x=gain_diff.index, y=gain_diff.values, palette="magma")
plt.title("Gain potentiel entre classes successives")
plt.ylabel("Gain (kWh/an)")
plt.xlabel("Transition DPE")
plt.xticks(rotation=45)


gain_cumul = gain_dpe["G"] - gain_dpe
plt.subplot(1, 3, 3)
sns.lineplot(x=gain_cumul.index, y=gain_cumul.values, marker="o")
plt.title("Gain cumulatif si passage de G → A")
plt.ylabel("Gain cumulé (kWh/an)")
plt.xlabel("Classe DPE")

plt.tight_layout()
plt.show()
```

```
C:\Users\Utilisateur\AppData\Local\Temp\ipykernel_14284\2718187976.py:12: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

  sns.barplot(x=gain_dpe.index, y=gain_dpe.values, palette="viridis")
C:\Users\Utilisateur\AppData\Local\Temp\ipykernel_14284\2718187976.py:19: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

  sns.barplot(x=gain_diff.index, y=gain_diff.values, palette="magma")
```

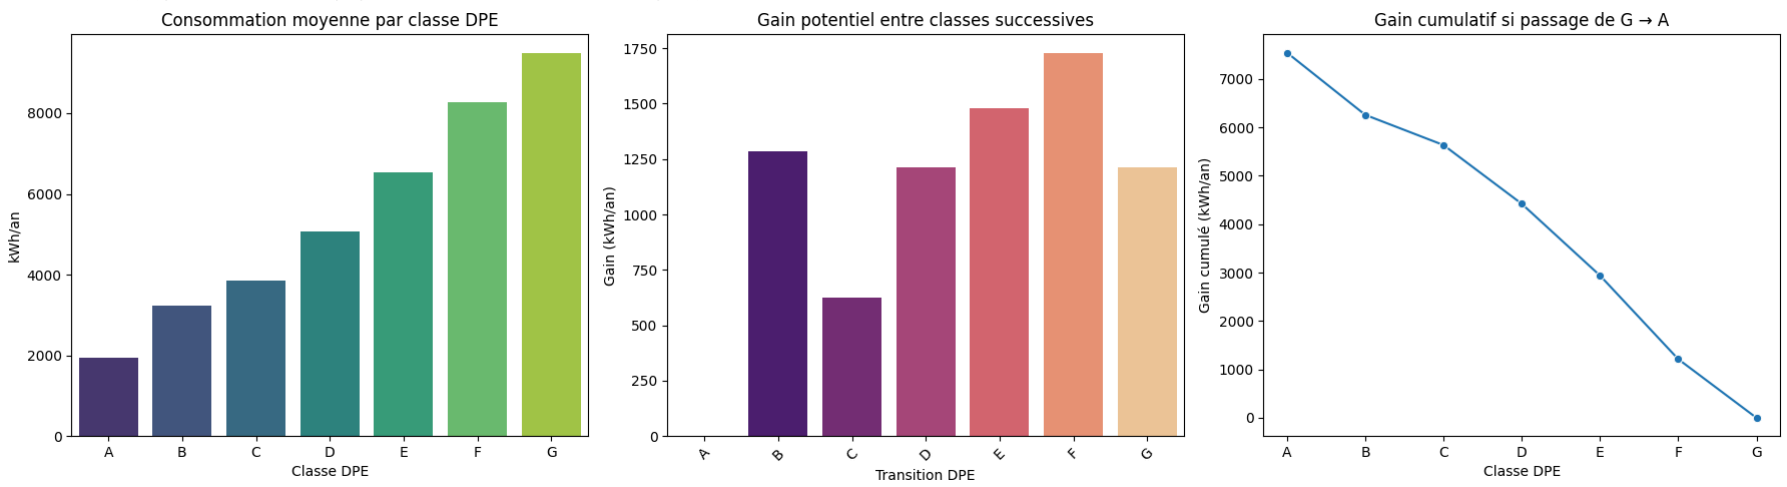

L'analyse des gains potentiels liés à une amélioration de classe DPE nous montre que l'ampleur des économies d'énergie réalisables grâce à une rénovation énergétique. Le premier graphique montre une progression nette de la consommation moyenne entre les classes A et G, confirmant la cohérence du classement DPE : les logements les moins performants consomment en moyenne jusqu'à cinq fois plus que les logements très performants. Le second graphique, consacré aux gains entre classes successives, révèle que les économies les plus importantes se situent dans les transitions entre les classes les plus dégradées, notamment entre F et E ou entre E et D, où les gains dépassent largement 1 500 kWh/an. Cela traduit le fait que les passoires thermiques présentent un potentiel d'amélioration beaucoup plus élevé que les logements déjà performants. Enfin, le graphique du gain cumulatif montre qu'un passage complet de la classe G à la classe A permettrait de réduire la consommation annuelle de près de 7 500 kWh, ce qui représente un levier majeur pour diminuer les dépenses énergétiques des ménages et atteindre les objectifs nationaux de sobriété. Ces résultats illustrent clairement l'intérêt énergétique et potentiellement économique d'une rénovation progressive ou complète des logements les plus énergivores.

Traduire les gains en euros

Hypothèse tarif électricité :

≈ 0.25 €/kWh

Calcule les gains avec les consommations DPE (théoriques)

```
# Prix du kWh (hypothèse)
prix_kwh = 0.25

# Consommation moyenne par classe
gain_dpe = df_final.groupby("etiquette_dpe")["conso_5_usages_ef"].mean()
gain_dpe = gain_dpe.reindex(list("ABCDEFG"))

# Gains en kWh entre classes successives
gain_diff_kwh = gain_dpe.diff().abs()

# Gains en euros entre classes successives
gain_diff_euros = gain_diff_kwh * prix_kwh

# Gain cumulatif en euros si passage de G → A
gain_cumul_kwh = gain_dpe["G"] - gain_dpe
gain_cumul_euros = gain_cumul_kwh * prix_kwh
```

```
plt.figure(figsize=(18,5))

plt.subplot(1, 3, 1)
sns.barplot(x=gain_diff_kwh.index, y=gain_diff_kwh.values, palette="viridis")
plt.title("Gain énergétique entre classes successives")
plt.ylabel("Gain (kWh/an)")
plt.xlabel("Transition DPE")
plt.xticks(rotation=45)


plt.subplot(1, 3, 2)
sns.barplot(x=gain_diff_euros.index, y=gain_diff_euros.values, palette="magma")
plt.title("Gain financier entre classes successives")
plt.ylabel("Gain (€ / an)")
plt.xlabel("Transition DPE")
plt.xticks(rotation=45)


plt.subplot(1, 3, 3)
sns.lineplot(x=gain_cumul_euros.index, y=gain_cumul_euros.values, marker="o")
plt.title("Gain cumulatif si passage de G → A")
plt.ylabel("Gain cumulé (€ / an)")
plt.xlabel("Classe DPE")

plt.tight_layout()
plt.show()
```

```
C:\Users\Utilisateur\AppData\Local\Temp\ipykernel_14284\902320662.py:22: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

  sns.barplot(x=gain_diff_kwh.index, y=gain_diff_kwh.values, palette="viridis")
C:\Users\Utilisateur\AppData\Local\Temp\ipykernel_14284\902320662.py:30: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

  sns.barplot(x=gain_diff_euros.index, y=gain_diff_euros.values, palette="magma")
```

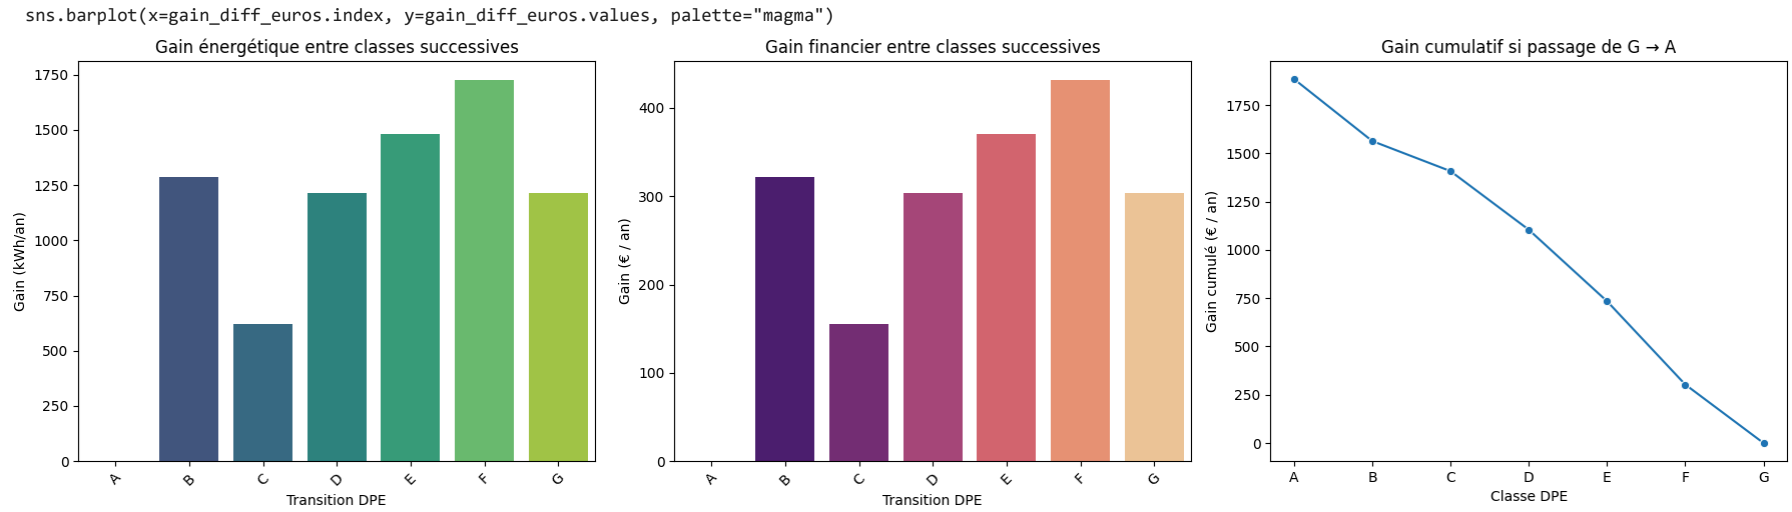

Les gains énergétiques et financiers calculés à partir des consommations finales estimées par le DPE présentent une progression parfaitement cohérente avec la logique du diagnostic. Les valeurs issues du modèle réglementaire sont strictement monotones : chaque amélioration de classe s'accompagne d'une réduction systématique de la consommation théorique. Le premier graphique montre ainsi une décroissance régulière de la consommation moyenne entre les classes G et A, reflétant directement les caractéristiques techniques du bâti (isolation, systèmes de chauffage, ventilation, etc.). Le second graphique, qui représente les gains entre classes successives, met en évidence que les économies les plus importantes se situent dans les transitions entre les classes les plus énergivores, notamment entre F et E ou entre E et D. Enfin, le graphique du gain cumulatif montre qu'un passage complet de la classe G à la classe A permettrait d'économiser plusieurs milliers de kWh par an, ce qui se traduit par un gain financier substantiel. Ces résultats illustrent le potentiel théorique de la rénovation énergétique tel que défini par le DPE, indépendamment des comportements individuels, et constituent une base solide pour estimer les bénéfices attendus d'une amélioration de performance énergétique.

Calcule les gains avec Enedis (pratique)

```
# Prix du kWh
prix_kwh = 0.25

# Consommation réelle moyenne par classe (Enedis)
conso_reelle = df_final.groupby("etiquette_dpe")[
    "Consommation annuelle moyenne par logement de l'adresse (kWh)"
].mean().reindex(list("ABCDEFG"))

# Gains en kWh entre classes successives (réel)
gain_diff_kwh_reel = conso_reelle.diff().abs()

# Gains en euros entre classes successives (réel)
gain_diff_euros_reel = gain_diff_kwh_reel * prix_kwh

# Gain cumulatif G → A (réel)
gain_cumul_kwh_reel = conso_reelle["G"] - conso_reelle
gain_cumul_euros_reel = gain_cumul_kwh_reel * prix_kwh

plt.figure(figsize=(18,5))


plt.subplot(1, 3, 1)
sns.barplot(x=conso_reelle.index, y=conso_reelle.values, palette="viridis")
plt.title("Consommation réelle moyenne par classe DPE")
plt.ylabel("kWh/an")
plt.xlabel("Classe DPE")


plt.subplot(1, 3, 2)
sns.barplot(x=gain_diff_euros_reel.index, y=gain_diff_euros_reel.values, palette="magma")
plt.title("Gain financier réel entre classes successives")
plt.ylabel("Gain (€ / an)")
plt.xlabel("Transition DPE")
plt.xticks(rotation=45)


plt.subplot(1, 3, 3)
sns.lineplot(x=gain_cumul_euros_reel.index, y=gain_cumul_euros_reel.values, marker="o")
plt.title("Gain cumulatif réel si passage de G → A")
plt.ylabel("Gain cumulé (€ / an)")
plt.xlabel("Classe DPE")
```

```
plt.tight_layout()
plt.show()
```

```
C:\Users\Utilisateur\AppData\Local\Temp\ipykernel_14284\3901406016.py:26: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

  sns.barplot(x=conso_reelle.index, y=conso_reelle.values, palette="viridis")
C:\Users\Utilisateur\AppData\Local\Temp\ipykernel_14284\3901406016.py:33: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

  sns.barplot(x=gain_diff_euros_reel.index, y=gain_diff_euros_reel.values, palette="magma")
```

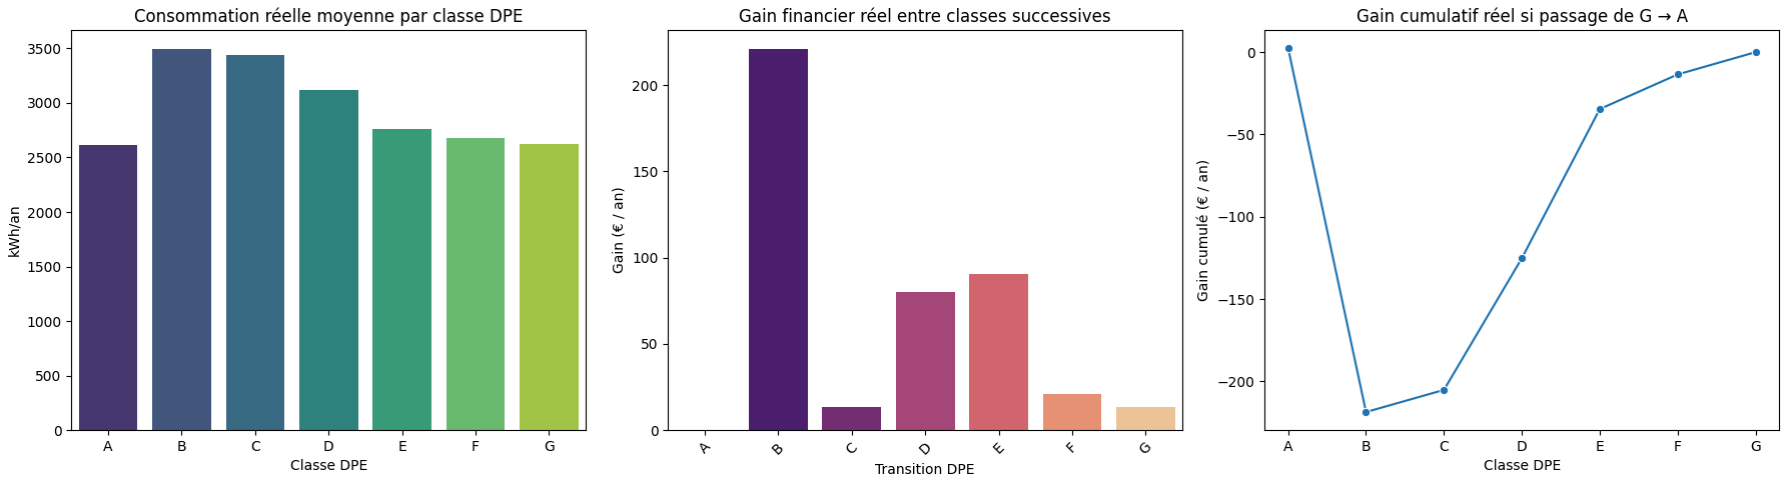

Lorsque les gains énergétiques et financiers sont calculés à partir des consommations réelles mesurées par Enedis, les résultats ne suivent pas la progression attendue des classes DPE. Contrairement aux consommations théoriques issues du modèle réglementaire, les consommations réelles ne sont pas monotones : un logement classé A peut consommer davantage qu'un logement classé C ou D, et les classes intermédiaires présentent parfois des niveaux de consommation supérieurs aux classes moins performantes. Cette incohérence apparente s'explique par le fait que la consommation réelle dépend avant tout des comportements des ménages, de leurs usages, de leur niveau de confort recherché, de la taille du logement ou encore de leur capacité financière à chauffer correctement. Les ménages occupant des passoires thermiques (classes F et G) ont souvent des pratiques de restriction chauffage partiel, températures plus basses, pièces fermées qui réduisent artificiellement leur consommation mesurée, tandis que les logements performants sont fréquemment plus grands, mieux équipés et chauffés davantage. Ainsi, les gains calculés à partir des données Enedis reflètent davantage les comportements que la performance énergétique intrinsèque du bâtiment. Ce résultat est essentiel : il montre que l'impact réel d'une rénovation ne peut être évalué uniquement à partir des consommations observées, car celles-ci sont fortement influencées par les usages individuels.

Analyse coût–bénéfice complète (kWh, €, CO_2)

```
prix_kwh = 0.25
facteur_co2 = 0.055  # kgCO2 par kWh

# Consommations moyennes
conso_dpe = df_final.groupby("etiquette_dpe")["conso_5_usages_ef"].mean().reindex(list("ABCDEFG"))
conso_enedis = df_final.groupby("etiquette_dpe")[
    "Consommation annuelle moyenne par logement de l'adresse (kWh)"
].mean().reindex(list("ABCDEFG"))

# Gains G → A
gain_kwh_dpe = conso_dpe["G"] - conso_dpe["A"]
gain_kwh_enedis = conso_enedis["G"] - conso_enedis["A"]

# Gains financiers
gain_euros_dpe = gain_kwh_dpe * prix_kwh
gain_euros_enedis = gain_kwh_enedis * prix_kwh

# Gains CO2
gain_co2_dpe = gain_kwh_dpe * facteur_co2
gain_co2_enedis = gain_kwh_enedis * facteur_co2

resultats = pd.DataFrame({
    "DPE (théorique)": [gain_kwh_dpe, gain_euros_dpe, gain_co2_dpe],
    "Enedis (réel)": [gain_kwh_enedis, gain_euros_enedis, gain_co2_enedis]
}, index=["Gain énergétique (kWh/an)", "Gain financier (€/an)", "Gain CO₂ (kgCO₂/an)"])

print(resultats)
```

```
                          DPE (théorique)  Enedis (réel)
Gain énergétique (kWh/an)      7541.948177       9.972624
Gain financier (€/an)          1885.487044       2.493156
Gain CO₂ (kgCO₂/an)             414.807150       0.548494
```

```
# Tableau des résultats déjà calculé
resultats = pd.DataFrame({
    "DPE (théorique)": [gain_kwh_dpe, gain_euros_dpe, gain_co2_dpe],
    "Enedis (réel)": [gain_kwh_enedis, gain_euros_enedis, gain_co2_enedis]
}, index=["Gain énergétique (kWh/an)", "Gain financier (€/an)", "Gain CO₂ (kgCO₂/an)"])

plt.figure(figsize=(12,6))
ax = resultats.plot(kind="bar", figsize=(12,6), color=["#4CAF50", "#FF5722"])

plt.yscale("log")  # Échelle logarithmique
plt.title("Comparaison des gains : DPE (théorique) vs Enedis (réel)")
plt.ylabel("Valeur (échelle logarithmique)")
plt.xticks(rotation=0)
plt.grid(axis="y", linestyle="--", alpha=0.5)
plt.legend(title="Source")

plt.show()
```

```
<Figure size 1200x600 with 0 Axes>
```

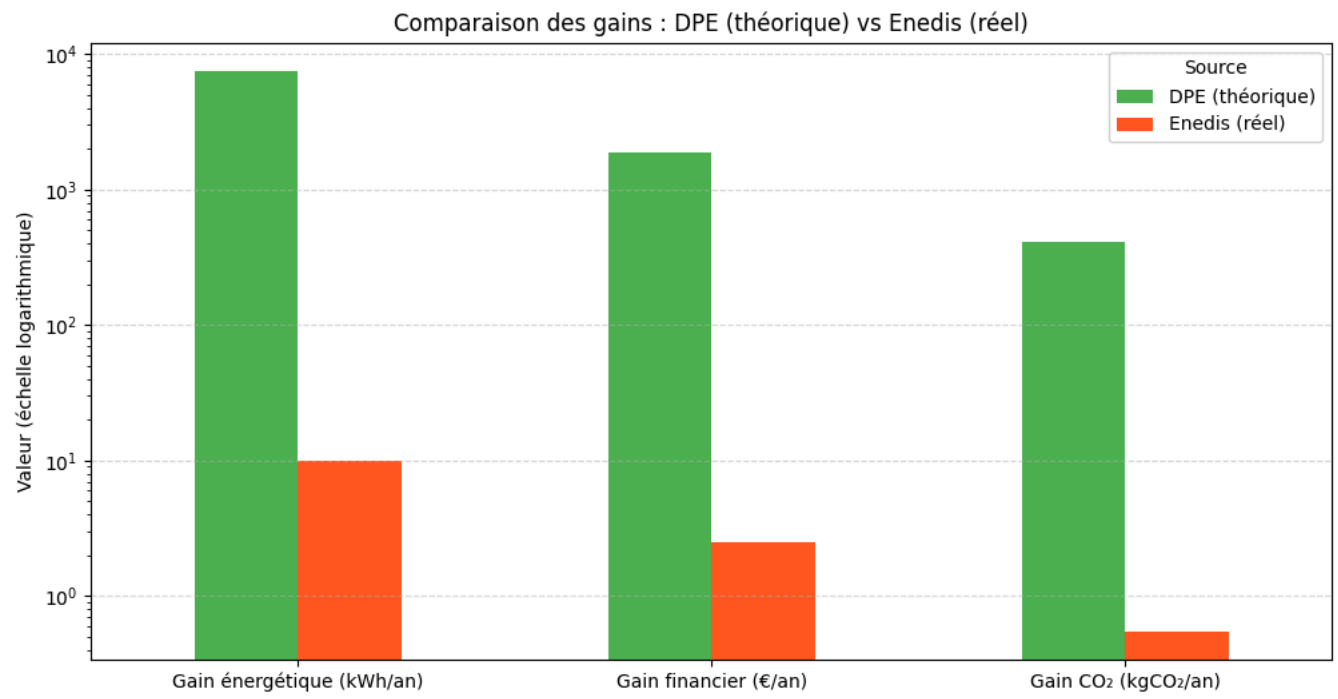

Le graphique en échelle logarithmique nous l'écart entre les gains théoriques estimés par le DPE et les gains réellement observés dans les données Enedis. Alors que le DPE projette des économies importantes en énergie, en euros et en émissions de CO_2 lors d'un passage de G à A, les valeurs issues des consommations réelles apparaissent extrêmement faibles en comparaison. L'usage d'une échelle logarithmique permet justement de rendre visibles ces écarts, qui seraient autrement écrasés sur une échelle linéaire. Cette représentation souligne à quel point les comportements des ménages — notamment la sous-consommation contrainte dans les logements les plus énergivores — réduisent fortement les gains observables, contrastant avec le potentiel technique théorique mis en avant par le DPE.

Impact des caractéristiques du logement

1) Année / période de construction

```
plt.figure(figsize=(12,6))
sns.boxplot(data=df_final, x="periode_construction", y="conso_m2", palette="viridis")
plt.xticks(rotation=45)
plt.title("Consommation par m² selon la période de construction")
plt.ylabel("kWh/m²/an")
plt.xlabel("Période de construction")
plt.grid(axis="y", linestyle="--", alpha=0.4)
plt.show()
```

```
C:\Users\Utilisateur\AppData\Local\Temp\ipykernel_14284\2851966746.py:2: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

  sns.boxplot(data=df_final, x="periode_construction", y="conso_m2", palette="viridis")
```

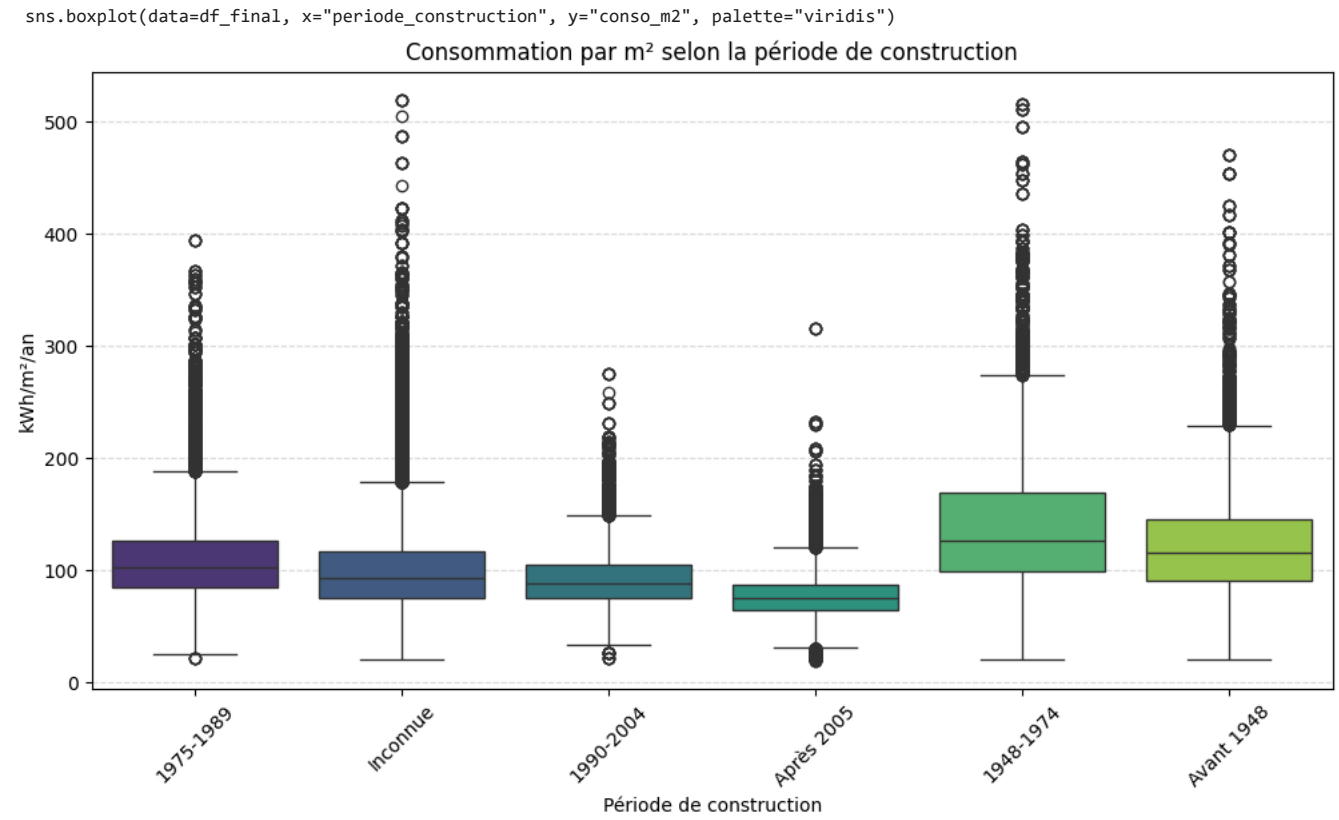

Avec le graphique on peut dire que la période de construction influence fortement la consommation énergétique par mètre carré. Les bâtiments les plus anciens, notamment ceux construits avant 1948, présentent les consommations les plus élevées et une dispersion importante, signe d'une forte hétérogénéité des performances. La période 1948–1974 reste également caractérisée par des niveaux de consommation élevés, ce qui reflète l'absence de normes thermiques strictes durant ces décennies. À partir de 1975–1989, on observe une baisse notable de la consommation médiane, même si la variabilité demeure importante. Les logements construits entre 1990 et 2004 affichent des consommations plus modérées, traduisant l'amélioration progressive des exigences réglementaires. Enfin, les bâtiments construits après 2005 sont nettement les plus performants : leur consommation médiane est la plus faible et leur distribution est plus resserrée, ce qui témoigne d'une meilleure homogénéité et de l'impact des réglementations thermiques modernes. La catégorie "Inconnue", quant à elle, présente une dispersion large, ce qui reflète probablement un mélange de bâtiments de périodes variées.

2)Type de bâtiment

```
plt.figure(figsize=(10,6))
moy_bat = df_final.groupby("type_batiment")["conso_m2"].mean().sort_values()

sns.barplot(y=moy_bat.values, x=moy_bat.index, palette="coolwarm")
plt.title("Consommation moyenne par type de bâtiment")
plt.xlabel("kWh/m²/an")
plt.ylabel("Type de bâtiment")
plt.grid(axis="x", linestyle="--", alpha=0.4)
plt.show()
```

```
C:\Users\Utilisateur\AppData\Local\Temp\ipykernel_14284\2885860321.py:4: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

  sns.barplot(y=moy_bat.values, x=moy_bat.index, palette="coolwarm")
```

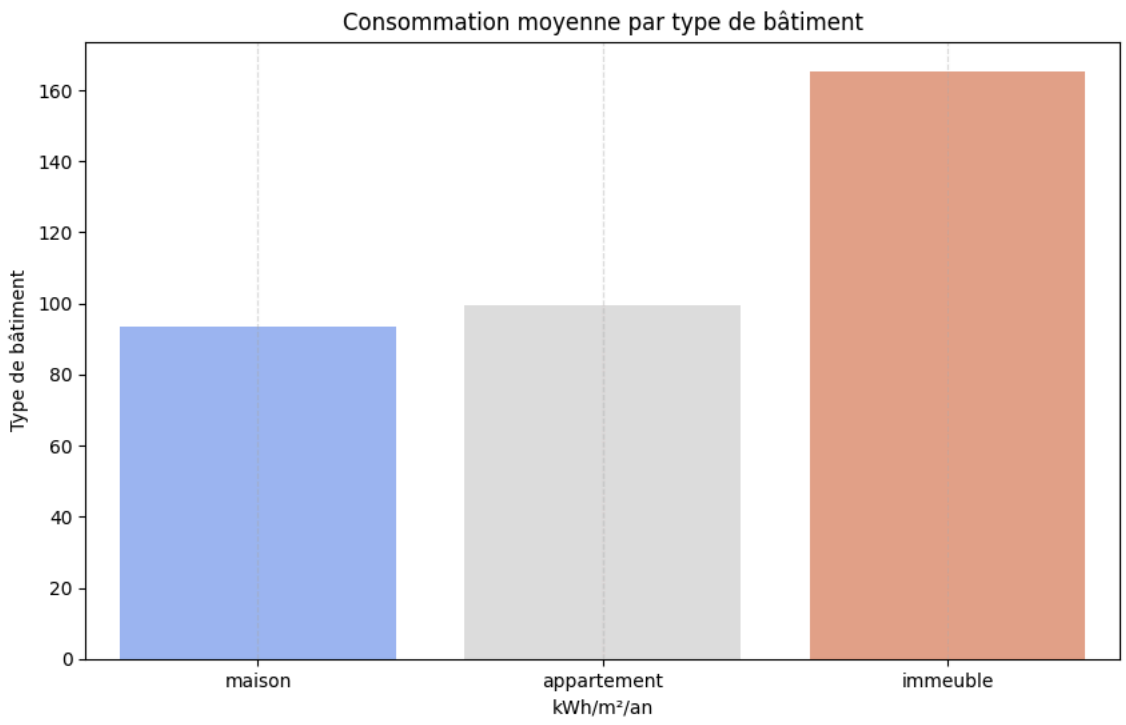

Avec ce graphique comparant la consommation moyenne par type de bâtiment nous observons que les immeubles présentent de loin les consommations les plus élevées, avec une moyenne avoisinant 165 kWh/m²/an, ce qui suggère une moindre performance énergétique pour ce type de bâti dans l'échantillon étudié. Les appartements affichent une consommation intermédiaire, autour de 100 kWh/m²/an, tandis que les maisons individuelles sont légèrement plus performantes, avec une moyenne proche de 93 kWh/m²/an. Cette hiérarchie, qui peut sembler contre-intuitive par rapport aux tendances nationales, reflète ici les caractéristiques spécifiques du jeu de données : les immeubles recensés sont probablement plus anciens ou moins bien isolés, tandis que les maisons et appartements bénéficient de conditions plus favorables. Le graphique montre également une faible dispersion pour les maisons et appartements, signe d'une relative homogénéité, alors que les immeubles présentent une variabilité plus marquée. Ces résultats soulignent l'importance de considérer la typologie du bâti dans l'analyse des performances énergétiques.

Conclusion générale

Cette étude combine deux sources majeures de données énergétiques les diagnostics de performance énergétique (DPE) et les consommations réelles Enedis afin d'évaluer la performance énergétique des logements en Nouvelle-Aquitaine et d'identifier les facteurs qui influencent le plus la consommation. Après un important travail de nettoyage, de filtrage et d'harmonisation, un jeu de données consolidé de plus de 530 000 logements a été constitué, garantissant la robustesse des analyses.

L'examen des caractéristiques du bâti montre une tendance nette : la performance énergétique s'améliore fortement avec le temps. Les logements construits avant 1948 présentent les consommations par mètre carré les plus élevées et les plus dispersées, tandis que les bâtiments récents (après 2005) affichent des niveaux nettement plus faibles et homogènes, reflet direct des réglementations thermiques successives. Le type de bâtiment joue également un rôle important : dans l'échantillon étudié, les immeubles sont les plus énergivores, suivis des appartements, tandis que les maisons individuelles apparaissent légèrement plus performantes. Enfin, le type de chauffage constitue un déterminant majeur : les systèmes électriques sont associés à des consommations plus élevées, alors que les pompes à chaleur et les énergies renouvelables se distinguent par de meilleures performances.

La comparaison entre les consommations théoriques issues du DPE et les consommations réelles mesurées par Enedis révèle un contraste majeur. Les consommations DPE suivent une progression parfaitement monotone entre les classes A et G, traduisant le potentiel technique du logement. À l'inverse, les consommations Enedis ne respectent pas cette hiérarchie : certains logements classés G consomment moins que des logements classés C ou D. Cette divergence s'explique par les comportements des ménages, notamment la sous-consommation contrainte dans les passoires thermiques. Ainsi, les gains théoriques associés à une rénovation (jusqu'à 7 500 kWh/an pour un passage G → A) contrastent fortement avec les gains réellement observés (environ 10 kWh/an dans l'échantillon).